



电网技术
Power System Technology
ISSN 1000-3673, CN 11-2410/TM

《电网技术》网络首发论文

题目: 基于 Koopman 时序延拓和 CNN-Transformer 模型的频率稳定指标预测
作者: 杨雨昕, 姚伟, 邓贤哲, 兰宇田, 黄伟, 董诗焘, 翟苏巍, 文劲宇
DOI: 10.13335/j.1000-3673.pst.2024.0686
网络首发日期: 2024-06-17
引用格式: 杨雨昕, 姚伟, 邓贤哲, 兰宇田, 黄伟, 董诗焘, 翟苏巍, 文劲宇. 基于 Koopman 时序延拓和 CNN-Transformer 模型的频率稳定指标预测[J/OL]. 电网技术.
<https://doi.org/10.13335/j.1000-3673.pst.2024.0686>



网络首发: 在编辑部工作流程中, 稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定, 且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式(包括网络呈现版式)排版后的稿件, 可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定; 学术研究成果具有创新性、科学性和先进性, 符合编辑部对刊文的录用要求, 不存在学术不端行为及其他侵权行为; 稿件内容应基本符合国家有关书刊编辑、出版的技术标准, 正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性, 录用定稿一经发布, 不得修改论文题目、作者、机构名称和学术内容, 只可基于编辑规范进行少量文字的修改。

出版确认: 纸质期刊编辑部通过与《中国学术期刊(光盘版)》电子杂志社有限公司签约, 在《中国学术期刊(网络版)》出版传播平台上创办与纸质期刊内容一致的网络版, 以单篇或整期出版形式, 在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊(网络版)》是国家新闻出版广电总局批准的网络连续型出版物(ISSN 2096-4188, CN 11-6037/Z), 所以签约期刊的网络版上网络首发论文视为正式出版。

基于 Koopman 时序延拓和 CNN-Transformer 模型的频率稳定指标预测

杨雨昕¹, *姚伟¹, 邓贤哲¹, 兰宇田¹, 黄伟², 董诗焘³, 翟苏巍³, 文劲宇¹

(1. 强电磁技术全国重点实验室(华中科技大学), 湖北省 武汉市 430074; 2. 云南电网有限责任公司昆明供电局, 云南省 昆明市 650012; 3. 云南电力调度控制中心, 云南省 昆明市 650011)

Frequency Stability Index Prediction Based on Koopman Time Series Extension and CNN-Transformer Model

YANG Yuxin¹, *YAO Wei¹, DENG Xianzhe¹, LAN Yutian¹, HUANG Wei²,
DONG Shitao³, ZHAI Suwei³, WEN Jinyu¹

(1. State Key Laboratory of Advanced Electromagnetic Technology(Huazhong University of Science and Technology), Wuhan 430074, Hubei Province, China; 2. Kunming Power Supply Bureau of Yunnan Power Grid Company Limited, Kunming 650012, Yunnan Province, China; 3. Dispatching Center of Yunnan Power Grid Corporation, Kunming 650011, Yunnan Province, China)

ABSTRACT: The proportion of new energy in the energy power generation structure has been greatly increased, which reduces the inertia level of the power system and weakens the frequency modulation ability of the system, resulting in increasingly prominent frequency stability problems. Therefore, it is very important to predict the frequency stability index of low inertia system after large disturbance. However, there is a contradiction between the prediction accuracy and timeliness of the existing methods. Therefore, this paper proposes a frequency stability index prediction method based on Koopman time series extension and CNN-Transformer model. The transient information after disturbance is used as input to predict the frequency stability index quickly and accurately. The proposed method extends the transient feature sequence in the time dimension based on the Koopman operator theory, and uses it as the input feature of the CNN-Transformer model to predict the frequency stability index. This method improves the timeliness of the prediction while satisfying the high-precision prediction. Finally, an example analysis is carried out on the IEEE-39 node system with wind power. The test results show that the MAPE errors of the frequency offset extremum and its arrival time are 1.02% and 0.11%, respectively, which are less than the current advanced algorithms, and the prediction time is only 30% of the general method. Experiments show that the

proposed method has higher accuracy and timeliness than the existing algorithms. At the same time, by visualizing the attention weight distribution, it is verified that the proposed model has certain interpretability.

KEY WORDS: frequency stability; CNN-Transformer model; attention visualization; Koopman operator theory; frequency online prediction

摘要: 新能源在能源发电结构中的比重大幅提升使得电力系统惯量水平降低, 削弱了系统调频能力, 导致频率稳定问题日益突出, 因此在大扰动后对低惯量系统进行频率稳定指标预测十分关键。然而现有方法在预测精度与时效性之间存在矛盾, 为此本文提出了一种基于 Koopman 时序延拓和 CNN-Transformer 模型的频率稳定指标预测方法, 以扰动后的暂态信息作为输入, 对频率稳定指标进行快速准确地预测。所提方法基于 Koopman 算子理论对暂态特征序列在时间维度上进行延拓, 以此作为 CNN-Transformer 模型的输入特征进行频率稳定指标的预测, 该方法在满足高精度预测的同时提升了预测的时效性。最后以含风电的 IEEE-39 节点系统为例进行算例分析, 测试结果表明频率偏移极值及其到达时间的 MAPE 误差分别为 1.02% 和 0.11%, 均小于当前先进算法, 且预测时间仅为一般方法的 30%, 实验证明所提方法相比现有算法具有更高的准确性和时效性。同时通过对注意力权重分布进行可视化, 验证了所提模型具有一定的可解释性。

关键词: 频率稳定; CNN-Transformer 模型; 注意力可视化; Koopman 算子理论; 频率在线预测

DOI: 10.13335/j.1000-3673.pst.2024.0686

基金项目: 中国南方电网云南电网有限责任公司科技项目(0500002022030301XT00090); 国家自然科学基金项目(U22B20111)。

Project supported by the Science and Technology Project of Yunnan Power Grid Co., Ltd. Of China Southern Power Grid(0500002022030301XT00090); The National Natural Science Foundation of China(U22B20111).

0 引言

随着新能源在能源发电结构中的比重份额逐年提升,我国电力系统正在逐渐演变为新型低惯量电力系统^[1-3]。新型电力系统惯量支撑能力弱、频率调节能力差,致使电力系统的频率稳定性明显削弱,这对电力系统稳定运行造成极大的威胁^[4-7]。因此在电力系统受到扰动后,需要准确高效地对系统暂态频率稳定进行在线分析和预测,以此帮助相关调度部门在故障后制订紧急控制策略来抑制频率失稳,保障系统安全稳定运行。

传统的频率稳定预测方法主要有时域仿真法和等值模型法两类。时域仿真通过求解由高阶非线性微分代数方程组表征的系统动态模型计算扰动后频率响应曲线,该方法计算精度高、可靠性强,但是时域仿真耗时较长,无法满足电网实时在线预测对于时效性的要求,并且由于电力系统结构复杂,搭建大规模系统的时域模型往往存在很大的困难^[8]。文献[9]和文献[10]分别提出平均系统频率(average system frequency, ASF)模型和系统频率响应(system frequency response, SFR)模型,以这两种模型为代表的等值模型法是对详细仿真模型采用惯性中心假设进行了一系列的近似简化,此类方法虽然极大缩减了计算量,但又因其高度简化导致模型计算精度较低,并还存在等值参数获取困难等问题^[11]。

随着人工智能的快速发展,以人工智能为代表数据驱动方法也受到了国内外研究学者们的广泛关注与运用^[12-14]。基于同步相量测量单元(phasor measurement unit, PMU)的广域量测系统(wide area measurement system, WAMS)在电力系统中大规模部署和应用,为数据驱动方法进行暂态频率稳定在线预测提供了丰富的暂态数据支持。文献[15]采用采用长短期记忆网络(long short term memory, LSTM)作为数据驱动方法,以系统时间序列数据作为输入,提取时序特征并修正 SFR 模型的预测。文献[16]提出一种基于 E3D-LSTM 模型的扰动后电网动态频率预测方法,在输入数据的前两个空间轴和第三时间轴上应用 3D 卷积,以保留输入信号在时间和空间上的原始信息,从而能够更好地捕获输入数据中的时空信息。但这些现有利用暂态信息进行频率指标预测的研究都存在预测精度与时效性之间的矛盾:若输入数据时长过短,则预测模型获

取信息不足,预测误差增大;若输入数据时长过长,预测精度满足要求但预测时效性有所下降。为解决预测精度与时效性之间的矛盾,文献[17-20]模型采用级联结构实现时间自适应以此来平衡预测精度与预测时间,但此类方法需要生成多个不同输入的评估模型,训练过程较为繁复。此外,许多文献在使用数据驱动方法进行预测时并未考虑到对模型的预测机理和决策过程进行展示和验证,整个预测过程呈现“黑箱”属性,这也是阻碍数据驱动方法在实际电网中大规模应用的一个重要原因,数据驱动方法缺乏可解释性导致电网调控部门对其计算结果的可靠性存在疑虑。

本文针对上述问题,提出一种基于 Koopman 时序延拓和 CNN-Transformer 模型的频率稳定指标预测方法。所提方法基于 Koopman 算子理论对扰动后短时间内采集的暂态数据进行时序延拓,再将延拓后的长时间序列作为 CNN-Transformer 模型的输入特征。相较于一般方法,所提方法即保证模型能够获取足够的暂态信息,又能够保证模型预测的时效性,解决了预测精度与时效性之间的矛盾。此外,本文通过对 Transformer 注意力分布进行可视化,体现了特征对于决策的贡献度,给频率稳定指标预测模型带来了一定的可解释性。在含风电的 IEEE-39 节点系统上的仿真结果验证了所提方法相较于常见算法具有更优越的性能。

1 基于 Koopman 时序延拓和 CNN-Transformer 模型的频率稳定指标预测框架

本文提出了一种基于 Koopman 时序延拓和 CNN-Transformer 模型的频率稳定指标预测方法,其整体预测框架如图 1 所示。预测框架整体由 PMU 时序特征数据采集、Koopman 时序延拓以及 CNN-Transformer 频率稳定指标预测模型三部分构成。在扰动发生后,首先通过 PMU 在一定时间段内进行多次采样,获取多维输入特征序列 $[X_1, X_2, X_3 \cdots X_n]$ 。其次,基于 Koopman 算子理论对输入特征序列在时间维度上进行延拓,得到延拓后的特征序列 $[X_1, X_2 \cdots X_n, X_{n+1} \cdots X_{n+m}]$ 。最后,将延拓后的特征序列输入到由 CNN-Transformer 构成的深度学习预测模型中,得到最终的频率稳定指标预测结果。

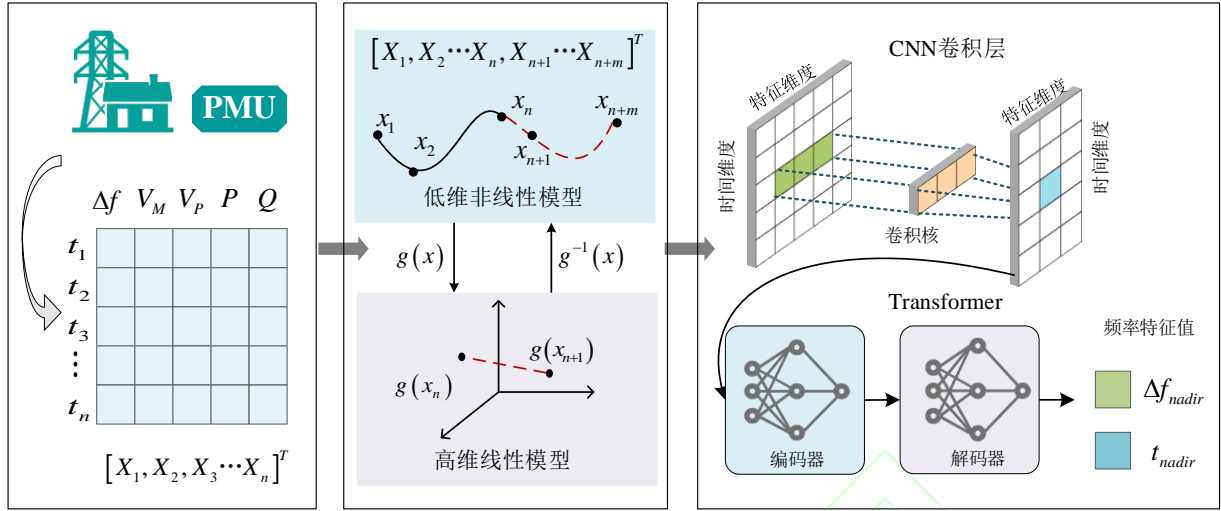


图1 基于Koopman时序延拓和CNN-Transformer模型的频率稳定指标预测框架

Fig. 1 Framework for frequency stability index prediction based on Koopman time series extension and CNN-Transformer model

1.1 基于Koopman算子理论的时序延拓

1.1.1 深度学习模型输入序列的时序延拓

基于扰动后暂态数据的频率预测方法的预测效果与输入时间序列的长短相关，且预测精度与时效性之间存在矛盾。若输入短时间序列则预测开始时刻早，但会导致深度学习预测模型获取的暂态信息不充分，模型预测误差较大。若输入长时间序列，虽然预测效果通常更好，但时序数据更多意味着需要更久的采样时间，模型开始预测时刻会更晚，预测时效性得不到保障。

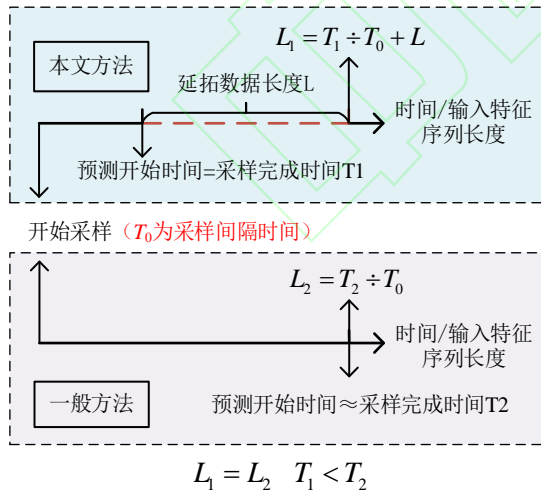


图2 本文方法与一般方法预测时效性对比

Fig. 2 Comparison of prediction timeliness between the method of this paper and general methods

为解决上述矛盾，本文提出结合Koopman时序延拓的频率预测方法。如图2所示(其中 T_0 为采样间隔时间，将序列中数据个数定义为数据长度 L)，相比于传统的深度学习预测模型，本文方法结合

Koopman算子理论对每种时序特征进行数据延拓，使其能够利用扰动短时间内采集的暂态数据延拓为长时间特征数据，从而保障模型预测精度。本文方法相较于一般方法开始预测的时刻更早，因此本文方法可以有效提高预测的时效性。

1.1.2 基于Koopman算子理论的时序延拓模型

Koopman算子是一种用于描述动态系统可观测量演化过程的工具。它的理论在动态系统性质研究中具有广泛的应用前景，可以描述非线性系统的可观测状态量在高维空间中的线性演化过程。基于Koopman算子理论的高维线性化思想，将系统扰动后短时间内PMU量测的时序数据视作离散非线性动力系统，通过升维变换将非线性动态模型转化为全局近似线性模型^[21]。PMU量测数据转换构建的高维线性模型可在线性空间中不断延伸出新的离散点，通过模型反映回非线性空间得到非线性空间中对点，即可实现时序数据的延拓。在实际应用中，基于Koopman算子理论进行时序延拓主要有三个优势：1) 不依赖于系统拓扑和模型参数，具有良好可扩展性。2) 计算精度高。3) 可解析求解，计算速度快，适合在线应用。

具体来说，我们通过构造Koopman算子的本征函数来得到系统的线性模型，该模型可以描述系统在可观测测量上的演化，其原理如图3所示^[22]。




图3 Koopman 算子理论的系统演进示意图

Fig. 3 Schematic diagram of system evolution based on Koopman operator theory

Koopman 算子理论的本质是通过坐标变换将非线性系统全局线性化，将离散非线性动力系统写作 $x_{t+1} = h(x_t)$ ，定义 Koopman 算子 \mathcal{K} 是一个作用在观测函数 $g(x)$ 上的线性运算符，满足：

$$\mathcal{K}g(x_t) = g(f(x_t)) = g(x_{t+1}) \quad (1)$$

将算子 \mathcal{K} 进行谱分解得到：

$$\mathcal{K}\varphi_j(x) = \lambda_j\varphi_j(x) \quad j=1,2,\dots,\infty \quad (2)$$

式中， φ_j 和 λ_j 表示是 Koopman 特征函数和特征值。

当可观测函数 $g(x)$ 落在 φ_j 张成的空间内时， $g(x)$ 可以表示为如下形式：

$$\begin{aligned} \mathcal{K}g(x) &= g(h(x)) = \sum_{j=1}^{\infty} \lambda_j \varphi_j(x) v_j \\ g(x_t) &= \sum_{j=1}^{\infty} \lambda_j^t \varphi_j(x_0) v_j \end{aligned} \quad (3)$$

式中，向量值的系数 v_j 被称为 Koopman 模式，则非线性系统完成了全局线性化。

实际上，无穷维度的观测函数和无穷维度的 \mathcal{K} 算子是难以选取和使用的，因此常用有限维度的空间将原无限维度作截断处理，从而得到 \mathcal{K} 算子的近似矩阵 M 。对于有限维度，将升维变换关系定义为 x_{lift} ，可以写作下式的形式：

$$x_{lift} = \begin{bmatrix} x \\ \psi(x) \end{bmatrix} \quad (4)$$

式中， $\psi(x)$ 为升维函数，又叫字典函数，其形式决定了 Koopman 算子的拟合精度。常见的选取方法有通用函数形式、神经网络训练和基于系统结构列写等。本文研究非线性系统模型函数关系复杂，选取新的状态空间变量难度较高，因此采用 polyharmonic 型通用升维函数进行升维运算，并对样本线性拟合，其形式如下：

$$\psi(x) = \sqrt{f_b(x - c_i)} \log \sqrt{f_b(x - c_i)} \quad (5)$$

实际应用时，在系统的历史运行数据中可以获

得各输入输出量的样本数据集：

$$X = [x_1 \cdots x_n], Y = [y_1 \cdots y_n] \quad (6)$$

基于以上样本，可通过最小二乘方法估计 M 矩阵进行拟合运算，得到 M 矩阵：

$$M = Y \cdot X_{lift}^T \cdot [X_{lift} \cdot X_{lift}^T]^\dagger \quad (7)$$

式中， $[\cdot]^\dagger$ 是 Moore-Penrose 逆矩阵运算的计算， X_{lift} 由样本数据 X 进行升维变换得到。

根据计算得到 M 矩阵，则高维线性模型输入、输出变量之间线性关系可表示为：

$$Y = M \cdot X_{lift} \quad (8)$$

基于以上过程非线性映射就可以转化为线性映射，实际应用中利用样本数据即可构建基于 Koopman 算子理论的时序延拓模型。

1.2 基于 CNN-Transformer 的频率稳定指标预测模型

本文使用 CNN-Transformer 作为深度学习预测模型，Transformer 的多头自注意力机制可捕捉识别序列依赖模式，引导模型聚焦重要特征，揭示不同特征对于决策的贡献度，从而更高效精准地对全局输入输出关系进行建模，并使模型更具可解释性。本文在 Transformer 模型的基础上加入 CNN 卷积层提取局部特征，为 Transformer 提供更高质量的输入数据^[23-25]。同时，加入卷积层对原始高维时序数据在特征维度上进行降维，合并特征减少了 Transformer 模型中数据交互的计算量，提高模型训练效率。因此相对于其他模型，本文模型不仅能高效精准地预测，而且更具可解释性且有更高的训练效率。

1.2.1 CNN-Transformer 模型结构设计

CNN-Transformer 模型整体结构设计如图 4 所示。标准 Transformer 模型由编码器和解码器两部分构成。针对本文研究的频率暂态稳定指标预测问题，本文保留 Transformer 的核心结构编码器，以线形层代替解码器。编码器主要多个相同的基础模块堆叠组成，基础模块主要包含多头注意力层、前馈神经网络层、残差连接和层归一化^[26]。位置编码描述模型特征向量中的位置关系，在分析电力系统暂态时序数据时，位置编码帮助模型识别特征在时间维度上的先后顺序。前馈神经网络层则使模型的非线性特征提取能力得到增强。在多头注意力层和前馈网络层之后引入残差连接和层归一化，加入残差连接结构可以有效避免梯度消失和模型退化的问题，而层标准化则通过将层输入规范为标准正态分布来加速模型的收敛。多头注意力层作为

Transformer 编码器的核心模块,在进行多次线性投影后并行执行注意力函数,这有助于模型在各个层面上捕捉关键信息^[27-28]。

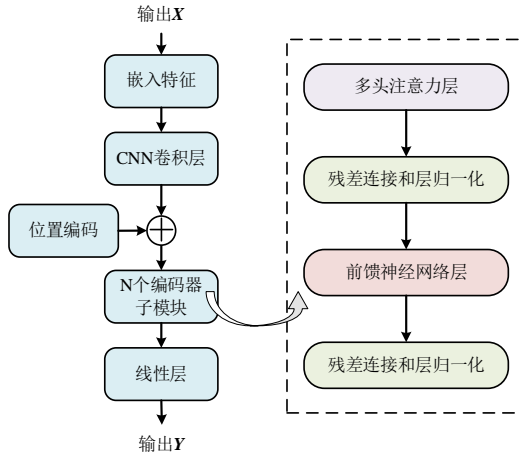


图4 CNN-Transformer 模型结构设计图

Fig. 4 Structure design diagram of CNN-Transformer model

1.2.2 Transformer 多头注意力机制

Transformer 模型的多头注意力机制采用点积注意力,计算过程如图5所示。

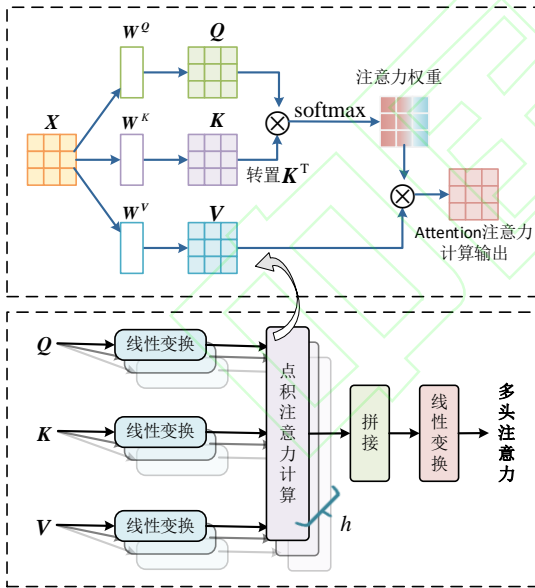


图5 Transformer 多头注意力机制计算过程

Fig. 5 Calculation process of multi-head attention mechanism in Transformer

查询矩阵 Q , 键矩阵 K 和值矩阵 V 由输入特征矩阵 X 经过不同线性变换得到:

$$\begin{cases} Q = W^Q X \\ K = W^K X \\ V = W^V X \end{cases} \quad (9)$$

式中, W^Q 、 W^K 和 W^V 为线性变换矩阵。

将 Q 、 K 、 V 进行 h 次投影后分别进行 Attention

注意力计算,并使用 Contact 函数将多组 d_k 维空间内的注意力计算结果进行拼接,最后连接所有子空间的注意力结果得到多头注意力层最终的输出结果,计算公式如下:

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V \quad (10)$$

$$H_i = \text{Attention}(QW_i^Q, KW_i^K, VW_i^V) \quad (11)$$

$$\text{MultiHead}(Q, K, V) = \text{Contact}(H_1, \dots, H_h)W^O \quad (12)$$

式中, softmax 函数获取值的权重,并有利于反向传播过程中的梯度计算; d_k 为缩放因子以避免点积过大造成 softmax 函数梯度太小; W_i^Q 、 W_i^K 和 W_i^V 分别是将 Q 、 K 、 V 矩阵投影到第 i ($i=1,2,3,\dots,h$) 个子空间的线性变换矩阵, h 为投影次数,也表示子空间数量; H_i 为第 i 个子空间的单头注意力值; W^O 为连接所有子空间 H_i 的权重矩阵。

1.2.3 注意力权重分布的简化

鉴于本文模型使用多头注意力且时序数据较长,为便于展示与分析对注意力权重分布图进行简化,处理流程如图6。




图6 注意力权重分布处理过程

Fig. 6 Process of handling attention weight distribution

根据 1.2.2 节可知,单头的注意力权重计算公式为:

$$A(Q, K) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right) \quad (13)$$

考虑所有特征量对于整体的重要程度,将所有子空间计算出的注意力权重进行平均值计算:

$$\tilde{A}(Q, K) = \frac{1}{h} \sum_{i=1}^h A(QW_i^Q, KW_i^K) \quad (14)$$

特征序列相邻的数据之间表达信息相似,因此有相似的注意力权重,将每十个时间点划分为一个时间区域,得到时间区域 $T_0 \sim T_9$ 。相应地将平均化后的注意力权重分布图进行时块划分,时间块对应的注意力权重值由时间块内所有的权重值累加而得,经过行标准化处理后得到最终的注意力权重分布图。

2 频率稳定指标预测方法应用流程

2.1 模型的输入输出特征

为了保障扰动后系统频率预测值的精准性，模型应当较为全面地模拟出频率响应的动态特性，因此输入特征也应该选取系统频率的重要影响因子，尽可能全面囊括系统的运行状态信息。本文选取如表 1 所示的 5 种系统暂态时序数据作为模型的输入特征量，包含同步机的频率偏移值、各同步发电机和风力发电机的电压幅值、电压相角、有功功率以及无功功率。每类特征量均是由多个 PMU 采样数据组成的特征序列，包含扰动发生后多个时间点的暂态信息。

表 1 样本集输入特征

Table 1 Input features of the sample set	
特征	符号
扰动各同步机频率偏移值	Δf
扰动后各发电机电压幅值	V_M
扰动后各发电机电压相角	V_P
扰动后各发电机有功功率	P
扰动后各发电机无功功率	Q

输出特征是为了满足实际应用需求而设立的指标，本文研究的主要目的是在大扰动下对低惯量电力系统的频率稳定进行预警，针对这一需求分析可知，输出特征应选择频率稳定评估指标。因此本文选取在频率稳定研究中广泛应用的频率偏移极值 Δf_{nadir} 及其到达时间 t_{nadir} 作为输出特征。

2.2 基于 Koopman 时序延拓和 CNN-Transformer 模型的频率稳定指标预测应用流程

综上，本文所提基于 Koopman 时序延拓和 CNN-Transformer 模型的频率稳定指标的实际应用流程如图 7 所示，主要分为样本集生成、离线训练和在线预测三个部分。

(1) 样本集生成：离线状态下，首先根据研究场景设计系统工况与扰动，形成样本生成方案。其次根据方案进行时域仿真，获取系统仿真运行数据。最后从仿真数据中提取出模型的输入、输出特征，生成样本集。

(2) 离线训练：离线状态下，基于所生成样本集的输入特征和输出特征，训练 CNN-Transformer 预测模型。然后对模型性能进行测试，经过多次调参后保存测试性能最佳的模型。

(3) 在线预测：在线状态下，首先在扰动发生后由 PMU 采集并上传各发电机节点的实测暂态运行数据。其次将每个特征序列分别基于 Koopman 算子理论进行时序延拓，得到长特征序列。最后将延拓后的特征序列输入到保存的 CNN-Transformer 模型中，输出频率稳定指标的预测结果。如需继续预

测，则等待下一阶段 PMU 上传数据后重复上述过程，反之结束。

根据频率稳定指标的最终在线预测值，即可判定扰动发生后系统是否需要发出频率稳定预警，为后续电力系统规划人员对保护装置是否进行操作提供频率判据，维护电网安全稳定运行。

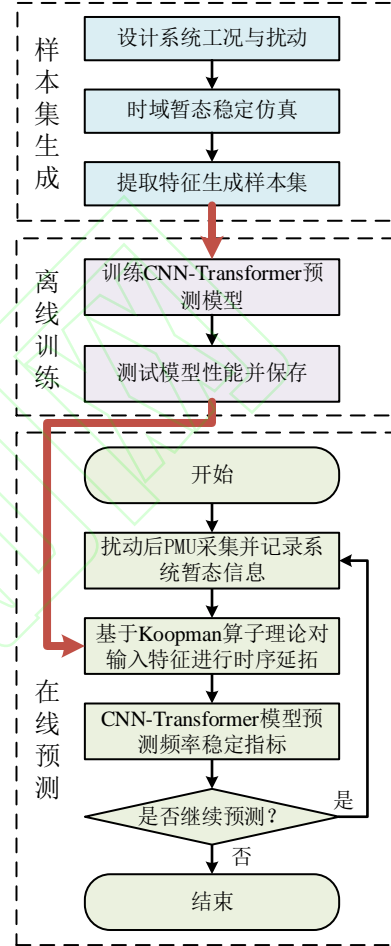


图 7 基于 Koopman 时序延拓和 CNN-Transformer 模型的频率稳定指标预测流程

Fig. 7 Flowchart of frequency stability index prediction based on Koopman time series extension and CNN-Transformer model

3 算例分析

为验证本文所提频率稳定指标预测方法的有效性，本文在含风电的 IEEE39 节点系统中所提方法进行测试和验证。本文样本由 MATLAB/Simulink 软件搭建模型仿真得到，深度学习模型由 Pytorch3.8 实现。

3.1 样本生成与评估指标

为考虑新能源发电对频率稳定的影响，本文测试系统基于 IEEE39 节点系统进行改进，具体如图 7 所示。风电场经节点 3、4、16、17、18 并入电网，各风电场分别由若干台额定容量为 2MW 的双馈风

力发电机组而成,风电机组采用下垂控制和虚拟惯量控制。

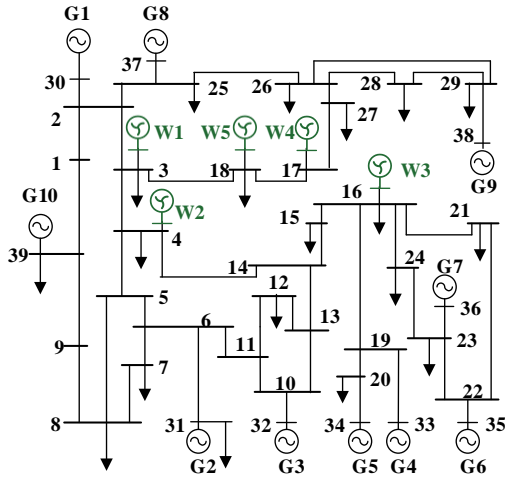


图 8 含风电的 IEEE39 节点系统单线图

Fig. 8 Single-line diagram of IEEE39 node system with wind power

表 2 样本生成方案

Table 2 Sample generation scheme

设置项目	设置内容	设置方法
稳态运行工况	风电渗透率	3.2~32% (以 3.2%为变化步长)
	负荷突变位置	节点 3、8、15、16、20、21、 24、27、29、39
预想扰动	负荷突变大小	±1~20% (以 1%为变化步长)

为实现所提频率稳定指标预测模型,提升模型泛化能力,设计样本生成方案应使其包含更多的系统稳态运行工况和预想扰动。考虑风力发电的随机性,本文改变风机出力分别设置风电渗透率为 3.2%, 6.4%, ..., 32% (以 3.2%为变化步长) 的 10 组稳态运行工况,并对应调整其他同步机出力以保证系统的稳定运行。同时设置随机有功扰动,在 10 个随机节点处增减负荷,设置扰动大小为总负荷功率的 ±1%, ±2%, ..., ±20% (以 1%为变化步长) 的多种有功扰动。系统额定频率为 50Hz。详细样本生成方案列于表 2 中。

将所有设定的系统稳态运行工况和预想扰动依次进行组合,并基于 MATLAB/Simulink 平台对所有样本进行仿真,采样间隔时间设置为 0.01s,测量并记录各发电机并网点扰动发生后的暂态数据信息。将所有样本随机分为 80%和 20%作为模型的训练集和测试集,保障二者无重叠。

本文研究的频率预测问题属于回归问题,选取常用来评估回归模型性能的平均绝对误差 (mean absolute error, MAE)、平均相对误差 (mean absolute percentage error, MAPE) 和均方根误差 (root mean

square error, RMSE) 作为模型评价分析的指标,其具体计算方法如下式:

$$MAE = \frac{1}{n} \sum_{i=1}^n (|y_i - x_i|) \quad (15)$$

$$MAPE = \frac{1}{n} \sum_{i=1}^n \left| \frac{y_i - x_i}{x_i} \right| \times 100\% \quad (16)$$

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - x_i)^2} \quad (17)$$

式中, x 表示目标值, y 表示模型输出预测值, n 为样本总数。

3.2 基于 Koopman 算子理论的时序延拓模型准确性验证

为测试基于 Koopman 算子理论的时序延拓模型的极限,设置如下算例:在风电渗透率为 3.2%的系统工况下,3 号节点的有功负荷突增 625MW。以 0.01s 的时间间隔采样记录暂态频率偏移值。使用 50 个采样数据 (即扰动后 0.5s 内的采样数据) 输入到 Koopman 时序延拓模型中,将模型数据延拓到 300 个 (即拟合扰动后 3s 内的采样数据)。以同步机 G5 的暂态频率偏移值为例,将实际采样数据曲线与 Koopman 时序延拓数据曲线进行对比,结果如图 9 所示。




图 9 扰动后同步机 G5 的暂态频率偏移值实际采样数据曲线与 Koopman 时序延拓曲线

Fig. 9 Actual sampling data curve of transient frequency offset value of synchronous machine G5 after disturbance and Koopman time series extension curve

由图可知,在少量数据输入的情况下,小范围内的时序延拓曲线与真实曲线之间吻合度较高。但随着延拓数据的不断增多,拟合的误差也会随之增加,由 Koopman 算子拟合获取的频率偏移极值误差高达 0.1Hz。实验证明 Koopman 算子本身不具有高精度预测整条频率曲线的能力,更无法直接高精度预测出本文所需频率稳定指标。因此,基于

Koopman 算子理论构建的时序延拓模型只能在一定长度内对时序数据进行延拓, 需要结合其他方法才能实现频率稳定指标的预测。

以暂态频率偏移值为例, 进一步验证本文所提基于 Koopman 算子理论的时序延拓模型在小范围内对于样本数据的延拓能力。分别使用基于 Koopman 算子理论和多项式拟合 (3 次) 两种时序延拓方式, 对 20、30、40 个初始频率偏移值采样数据进行不同长度的延拓, 计算延拓数据的 MAPE 误差。实验结果如表 3, 其中, L_0 为输入采样序列长度, L 为延拓输出序列长度。

表 3 基于 Koopman 算子理论和多项式拟合两种时序延拓方法的 MAPE 对比

L	MAPE/%					
	$L_0=20$		$L_0=30$		$L_0=40$	
	本文方法	多项式拟合	本文方法	多项式拟合	本文方法	多项式拟合
30	0.17	0.20	/	/	/	/
40	0.58	0.75	0.04	0.05	/	/
50	1.17	1.75	0.11	0.13	0.04	0.03
60	1.89	3.28	0.23	0.27	0.14	0.12
70	2.69	5.38	0.42	0.48	0.32	0.30
80	3.55	7.66	0.70	0.79	0.60	0.63
90	4.84	10.21	1.09	1.24	0.99	1.16
100	6.48	12.47	1.61	2.09	1.45	1.86

实验结果表明, 保持相同的延拓长度, 随着输入采样序列长度的增加, 整体延拓的 MAPE 误差会减小。同时随着延拓输出序列长度的增加, 拟合数据的误差也会随之增加, 但小范围内的总体延拓误差很小。在不同的输入输出长度下, 基于 Koopman

算子理论的延拓精度均高于使用多项式拟合的精度, 在最极端的情况下 (输入数据仅 20 个, 输出数据 100 个), 多项式拟合的 MAPE 高达 12.47%, 无法满足实际精度要求, 而本文使用的基于 Koopman 算子理论的延拓模型 MAPE 为 6.48%, 与多项式拟合相比误差相对减少了 50%, 由此可以证明本文所提基于 Koopman 算子理论的时序延拓模型在准确性上有明显优势。

3.3 消融实验

对所提方法进行消融实验, 以此验证模型各模块的有效性和必要性。消融实验中, 模型一为基础模型 Transformer, 在基础模型中依次加入 CNN 卷积层和 Koopman 数据延拓部分构建模型二和模型三, 增加模型四以验证本所提方法的时效性。消融实验各模型详细设置列于表 4, 所有模型的 Transformer 编码器均采用 2 个子模块进行堆叠, 多头注意力中头数 h 为 8。

表 4 消融实验模型设置

模型序号	模型结构设计	PMU 采样序列长度	时序延拓输出序列长度
模型一	Transformer	30	\
模型二	CNN-Transformer	30	\
模型三	Koopman 数据延拓 + CNN-Transformer	30	100
模型四	CNN-Transformer	100	\

将各模型分别进行训练并测试频率稳定指标的预测误差, 同时记录下各部分模块的操作时长, 相加计算模型总体预测时间。模型总体预测时间 T 主要考虑以下三部分: 暂态数据采集时间 T_s 、Koopman 时序延拓时间 T_k 和深度学习模型预测时间 T_p 。消融实验结果对比如图 10 和表 5 所示。




图 10 消融实验预测误差对比

Fig. 10 Comparison of prediction errors in ablation experiment

表 5 消融实验预测误差以及操作时间对比

Table 5 Comparison of prediction errors and operation time in ablation experiment

模型	频率偏移极值			频率偏移极值到达时间			操作时长			
	RMSE/10 ⁻²	MAPE/%	MAE/10 ⁻² Hz	RMSE/10 ⁻²	MAPE/%	MAE/10 ⁻² s	T_s/s	$T_k/10^{-4}s$	$T_p/10^{-5}s$	T/s

模型一	1.54	4.24	1.20	1.50	0.31	1.06	0.3	\	3.30	0.300033
模型二	0.88	2.07	0.60	0.86	0.19	0.64	0.3	\	0.80	0.300008
模型三	0.41	1.02	0.24	0.50	0.11	0.38	0.3	1.99	1.70	0.300216
模型四	0.39	0.79	0.20	0.46	0.10	0.37	1	\	1.80	1.000018

从各模型预测误差的对比可以看出,基础模型Transformer 预测误差最大,模型一、二、三各项误差依次减小。模型二加入 CNN 卷积层对模型整体预测效果有明显提升,这应当部分归因于 CNN 卷积层高效的局部特征提取能力,并且加入 CNN 卷积层合并特征后的模型二相较于基础模型其深度学习预测时长更短。模型三中加入时序延拓部分后预测精度得到提高的主要原因是延拓后的长特征序列能够为深度学习模型提供更加全面的数据信息。分析模型三各部分模块的操作时长,Koopman 时序延拓的操作时间为 $1.99 \times 10^{-4} \text{s}$,深度学习模型预测的操作时间为 $1.70 \times 10^{-5} \text{s}$,二者均远小于暂态数据采集时间,对于整体预测的时效性几乎无影响。对比模型三和模型四可以发现,相比于使用长时间采样数据的一般方法,所提方法(即模型三)预测结果误差仅略有增加,但在牺牲少量精度的同时预测时间大幅缩短,仅为一般方法(模型四)的 30%。这是由于时序延拓时间和深度学习模型预测时间

都很短,二者相较于采样时间可忽略不计,本文方法加入基于 Koopman 算子理论的时序延拓模块减少采样时长,相较于一般方法开始预测的时刻更早,因此能从本质上解决利用暂态数据进行预测的时效性问题。综上所述,本文方法具有较好的预测精度和时效性,同时消融实验证明所提方法加入各模块的有效性和必要性。

3.4 对比实验

为进一步验证本文频率稳定指标预测模型的准确性,将本文方法与常用的时序预测模型卷积神经网络(convolutional neural networks, CNN)、循环神经网络 RNN(recurrent neural network, RNN)、长短期记忆网络 LSTM、时序卷积网络(temporal convolutional networks, TCN)和门控循环单元(gated recurrent unit, GRU)神经网络进行比较^[31-32],各模型输入数据均为扰动发生后 0.3s 内的采样数据,本文方法设置 Koopman 时序延拓部分将原始输入数据延拓到 1s,频率稳定指标的预测误差如表 6 所示。

表 6 不同预测模型的误差对比

Table 6 Error comparison of different prediction models

模型	频率偏移极值			频率偏移极值到达时间		
	RMSE/ 10^{-2}	MAPE/%	MAE/ 10^{-2}Hz	RMSE/ 10^{-2}	MAPE/%	MAE/ 10^{-2}s
RNN	2.08	8.09	1.62	5.30	1.15	4.04
CNN	1.44	4.17	1.20	3.71	0.79	2.27
LSTM	1.12	3.25	0.90	3.01	0.75	2.59
TCN	0.62	1.33	0.37	1.56	0.41	1.24
GRU	0.85	2.02	0.63	1.37	0.29	1.01
本文方法	0.41	1.02	0.24	0.50	0.11	0.38

从表 6 对比可知,本文方法在预测精度上相较于其他机器学习模型有明显的优势,本文方法相对于 CNN、RNN、LSTM、TCN 和 GRU,频率偏移极值的 MAPE 误差分别减小了 7.07%、3.15%、2.23%、0.31%和 1.00%,频率偏移极值到达时间的 MAPE 误差分别减小了 1.04%、0.68%、0.64%、0.30%和 0.18%。实验结果表明本文方法可以充分挖掘电力系统暂态过程中 PMU 量测数据的时序信息,并能够高精度地建立时间序列特征与系统频率稳定评估指标之间的映射关系,有助于进一步提高电力系统暂态稳定评估的准确性。

3.5 Transformer 注意力可视化

深度学习算法所表现出的“黑箱”特性,导致模型在可解释性方面表现不佳,阻碍了其在实际工程场景中的信任度与接纳度。而注意力机制凭借其在特征权重分布可视化方面的优秀性能,正逐渐被

引入到模型可解释性分析的实践中,其体现为:注意力权重值越大的特征对模型决策过程的影响更大^[29]。本文方法能够利用特征注意力分布,将 Transformer 模型中间计算权重的过程进行可视化,以此揭示特征对于决策的贡献程度,这不仅可以增强模型的可解释性,也能为特征数据选取方向提供有益的指导。

现对 3.3 节中模型三和模型四的自注意力权重进行分析,注意力可视化结果如图 11 所示。从整体对比使用延拓数据的模型三与完全使用采样数据的模型四,二者注意力权重分布具有非常高的相似性,由此也可以证明使用基于 Koopman 算子理论进行数据延拓对深度学习模型预测过程的影响较小,所提方法具有可行性。单独分析各自注意力层的权重,第一层中第 9 时间区域的权重值较高,第二层中第 0、1、2 时间区域的权重值较高。时间

区域的权重值较高表征第 0~2 以及第 9 时间区域是整体特征序列中模型投入高度注意力的区域，对模型预测结果有更强的干涉影响和预测贡献度。高注意力特征主要分布在序列的开始与结尾部分，这可能是因为首尾部分特征的时间跨度较大，特征包含的暂态运行信息会有明显的差别，更能够反映出系统的稳定状态，因此在系统暂态稳定分析问题中，最好选择时间跨度大的系统暂态运行数据作为输入特征。

基于上述分析，为验证模型特征注意力权重分布的有效性，将注意力权重值高的第 0、1、2、9 时间区域的特征数据拼接为高注意力特征序列，余下第 3~8 时间区域的特征数据拼接为低注意力特征序列。分别采用高、低注意力特征序列构建样本特征集并训练 CNN-Transformer 模型，对照组（3.3 节模型四）输入特征为第 0~9 时间区域构成的全特征序列，模型预测误差如表 7。

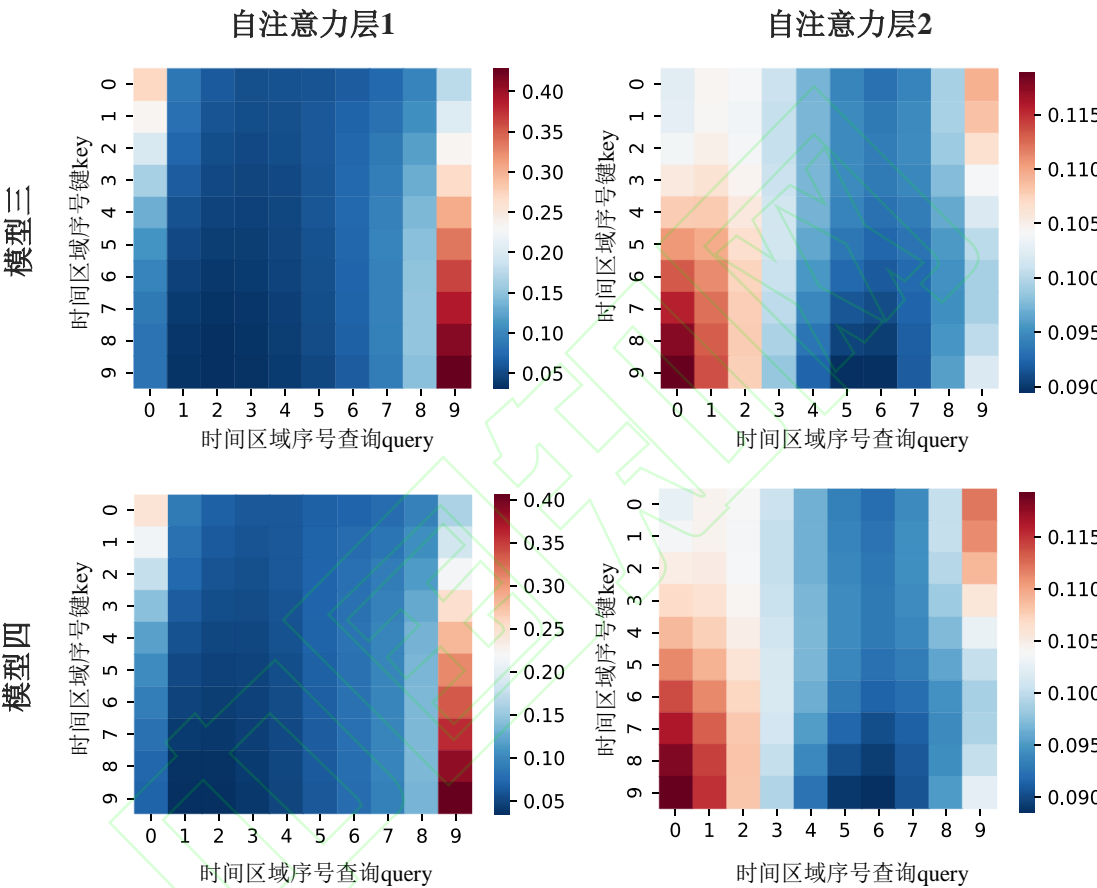


图 11 模型注意力权重分布对比

Fig. 11 Comparison of model attention weight distribution

表 7 采用不同注意力特征序列后预测误差对比

Table 7 Comparison of prediction errors after using different attention feature sequences

输入特征	频率偏移极值			频率偏移极值到达时间		
	RMSE/ 10^{-2}	MAPE/%	MAE/ 10^{-2} Hz	RMSE/ 10^{-2}	MAPE/%	MAE/ 10^{-2} s
低注意力特征序列	0.88	2.55	0.63	0.92	0.20	0.69
高注意力特征序列	0.47	1.22	0.32	0.73	0.16	0.54
全特征序列	0.41	1.02	0.24	0.50	0.11	0.38

实验结果表明，仅使用高注意力特征序列进行预测，频率偏移极值的 MAPE 约为 1.22%，频率偏移极值到达时间的 MAPE 约为 0.16%，其预测精度高，且与使用全序列特征的对照组结果接近，说明注意力有效识别了高价值特征，与注意力权重分布结果相符。对比使用高、低注意力特征序列的预测误差，采用高注意力输入特征序列的模型有更好的

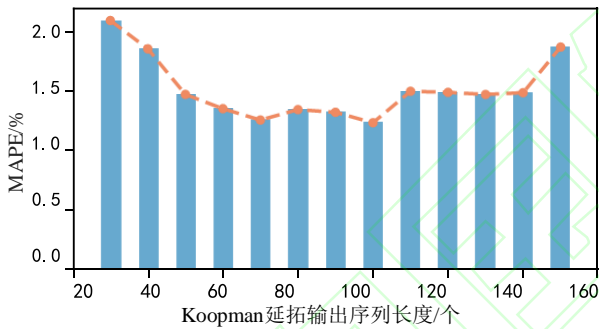
预测效果，表明高注意力权重的特征会更大程度上影响模型决策。

综上所述，实验证明具有较高注意力权重的特征会在更大程度上影响模型的决策过程，针对暂态稳定性分析问题，本文模型相较于其他常见的深度网络展现出了显著的可解释性优势。


3.6 基于 Koopman 算子理论时序延拓长度的影响

由前文分析可知: CNN-transformer 模型中, 通常输入时间序列越长, 预测结果误差越小; 但在基于 Koopman 算子理论的时序延拓模型中, 延拓长度越长时, 其延拓数据的误差就越大。因此本文方法应用时应该考虑时序延拓长度的影响, 若延拓长度太短, 则无法充分发挥本文方法的优势, 预测效果达不到最佳; 若延拓长度太长, 则深度学习模型输入特征数据与真实采样数据之间误差过大会导致模型输出结果偏离实际结果, 最终预测误差可能反而增加。

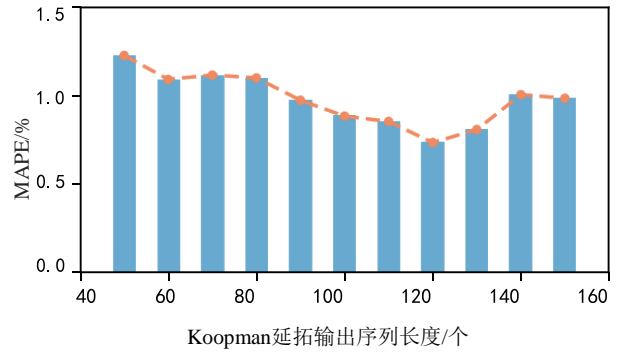
为选取合适的延拓长度, 需进一步探究基于 Koopman 算子理论的时序延拓模型在不同输入、输出序列长度下, 对本文方法预测误差的影响。分别使用 20、30、40 个采样数据延拓到不同长度, 将延拓模型的输出序列作为 CNN-Transformer 模型的输入序列, 获取频率偏移极值的预测结果。预测误差如图 12 和表 8 所示, 其中, L_0 为输入采样序列长度, L 为延拓输出序列长度。



(a) 使用 20 个采样数据延拓结果



(b) 使用 30 个采样数据延拓结果



(c) 使用 40 个采样数据延拓结果

图 12 延拓不同长度后频率偏移极值 MAPE 变化
Fig. 12 Change of MAPE of frequency offset extremes after extension with different lengths

表 8 延拓不同长度后频率偏移极值 MAPE
Table 8 MAPE of frequency offset extremes after extension with different lengths

L	MAPE/%		
	$L_0=20$	$L_0=30$	$L_0=40$
30	2.09	\	\
40	1.85	1.78	\
50	1.47	1.42	1.23
60	1.35	1.26	1.09
70	1.26	1.18	1.12
80	1.35	1.12	1.10
90	1.32	1.01	0.97
100	1.24	1.02	0.89
110	1.50	0.99	0.86
120	1.49	0.96	0.74
130	1.47	1.16	0.81
140	1.49	1.28	1.01
150	1.87	1.09	0.99

实验结果表明, 随着延拓输出序列的长度增加, 初始时预测误差逐步降低, 但延拓输出序列的长度增加到一定程度后, 预测误差变化趋势平缓, 甚至会增大。鉴于较长的特征序列会使模型训练负担加大, 且序列长度进一步增加并没有换得性能的提高, 因此认为延拓后模型输出序列长度为初始输入采样序列长度的 3 倍左右是较合理的选取范围。

3.7 模型面对新场景的泛化能力

因电力系统实际应用场景千变万化, 为验证模型面对新场景的泛化能力, 重新仿真生成与原始样本集完全不同的新样本^[30]。分别在节点 7 与节点 18 处增减负荷, 设置扰动大小为总负荷功率的 $\pm 21\%$, $\pm 22\%$, \dots , $\pm 25\%$ (以 1% 为变化步长) 的多种有功扰动, 风电渗透率设置同 3.1 节。获取新样本后使用 3.4 节中的多个模型对新样本的频率偏移极值及其到达时间进行预测, 预测误差如表 9 所示。

表 9 模型面对新场景的预测误差
Table 9 The prediction error of the model in the face of new scenarios

模型	频率偏移极值			频率偏移极值到达时间		
	RMSE/10 ⁻²	MAPE/%	MAE/10 ⁻² Hz	RMSE/10 ⁻²	MAPE/%	MAE/10 ⁻² s
RNN	18.69	16.73	15.19	37.26	10.07	34.30
CNN	11.51	10.50	10.96	47.80	13.94	47.56
LSTM	13.04	11.28	10.07	17.76	4.54	15.18
TCN	6.21	5.79	5.56	8.82	2.44	8.28
GRU	7.11	6.83	6.37	2.98	0.70	2.37
本文方法	2.24	4.44	1.90	2.07	0.53	1.32

由表 9 可知，在面对大量新场景时，本文方法的预测误差依旧很小，频率偏移极值及其到达时间的 MAPE 值分别为 4.44% 和 0.53%，均优于其他算法，这主要是因为 Transformer 特征间进行多头注意力运算，使模型更好地建立全局联系，因此相对于其他常见算法具有更强地泛化能力。实验证明本文方法面对新场景有较好的适应性，模型表现出了良好的泛化能力。

4 结论

本文提出了一种基于 Koopman 时序延拓和 CNN-Transformer 模型的频率稳定指标预测方法，以扰动后的暂态信息作为输入，对频率稳定指标进行快速准确地预测。相关结论如下：

(1) 本文所提频率稳定指标预测方法将基于 Koopman 算子理论的时序延拓模型与深度学习预测模型相结合。所提方法相较于一般方法时效性大幅提升，在本文算例中预测时间仅为原来的 30%。

(2) 本文采用扰动后的暂态运行信息，设计了基于 CNN-Transformer 的频率稳定指标预测模型，实现了扰动后频率稳定指标的精准预测。本文方法测试结果表明频率偏移极值及其到达时间的 MAPE 误差分别为 1.02% 和 0.11%，相对于常用的时序预测模型 CNN、RNN、LSTM、TCN 和 GRU，频率偏移极值的 MAPE 误差分别减小了 7.07%、3.15%、2.23%、0.31% 和 1.00%，频率偏移极值到达时间的 MAPE 误差分别减小了 1.04%、0.68%、0.64%、0.30% 和 0.18%。

(3) 本文通过对 Transformer 注意力分布进行可视化，体现了特征对于决策的贡献度，验证本文方法具有一定的可解释性，能够提升所提方法在实际工程场景中的信任度与接纳度，满足扰动后在线稳定评估的需求。

参考文献

[1] 文云峰, 杨伟峰, 林晓煌. 低惯量电力系统频率稳定分析与控制研究综述及展望[J]. 电力自动化设备, 2020, 40(09): 211-222.

Wen Yunfeng, Yang Weifeng, Lin Xiaohuang. Review and prospect of frequency stability analysis and control in low inertia power systems[J]. Electric Power Automation Equipment, 2020, 40(09): 211-222(in Chinese).

[2] 刘翔宇, 李晓明, 朱介北, 等. 新型电力系统的频率响应模型综述及展望[J]. 南方电网技术, 2022, 16(10): 38-47.

Liu Xiangyu, Li Xiaoming, Zhu Jiebei, et al. Review and prospect of frequency response models for new power systems[J]. Southern Power Grid Technology, 2022, 16(10): 38-47(in Chinese).

[3] 康重庆, 杜尔顺, 郭鸿业, 等. 新型电力系统的六要素分析[J]. 电网技术, 2023, 47(05): 1741-1750.

Kang Chongqing, Du Ershun, Guo Hongye, et al. Analysis of six elements in new type of power system[J]. Power System Technology, 2023, 47(05): 1741-1750(in Chinese).

[4] 张子扬, 张宁, 杜尔顺, 等. 双高电力系统频率安全问题评述及其应对措施[J]. 中国电机工程学报, 2022, 42(01): 1-25.

hang Ziyang, Zhang Ning, Du Ershun, et al. Review of frequency safety issues in dual high power systems and their countermeasures[J]. Proceedings of the Chinese Society for Electrical Engineering, 2022, 42(01): 1-25(in Chinese).

[5] 李卫东, 晋萃萃, 温可瑞, 等. 大功率缺失下主动频率响应控制初探[J]. 电力系统自动化, 2018, 42(8): 22-30.

Li Weidong, Jin Cuicui, Wen Kerui, et al. Preliminary exploration of active frequency response control under large power loss[J]. Automation of Electric Power Systems, 2018, 42(8): 22-30(in Chinese).

[6] 王路平, 谢小荣, 刘颖, 等. 多直流馈入受端电网短期频率稳定性的实时协调控制方法[J]. 中国电机工程学报, 2018, 38(8): 2205-2212.

Wang Luping, Xie Xiaorong, Liu Ying, et al. Real-time coordinated control method for short-term frequency stability of DC-fed receiving network[J]. Proceedings of the Chinese Society for Electrical Engineering, 2018, 38(8): 2205-2212(in Chinese).

[7] 马宁宁, 谢小荣, 贺静波, 等. 高比例新能源和电力电子设备电力系统的宽频振荡研究综述[J]. 中国电机工程学报, 2020, 40(15): 4720-4732.

Ma Ningning, Xie Xiaorong, He Jingbo, et al. Review of wide-frequency oscillation in power systems with high proportion of new energy and power electronic devices[J]. Proceedings of the Chinese Society for Electrical Engineering, 2020, 40(15): 4720-4732(in Chinese).

[8] 倪以信, 陈寿孙, 张宝霖. 动态电力系统的理论和分析[M]. 北京: 清华大学出版社, 2002.

[9] Chan M L, Dunlop R D, Schweppe F. Dynamic equivalents for average system frequency behavior following major disturbances[J]. IEEE Transactions on Power Apparatus and Systems, 1972, PAS-91(4): 1637-1642.

[10] Anderson P M, Mirheydar M. A low-order system frequency response model[J]. IEEE Transactions on Power Systems, 1990, 5(3): 720-729.

- [11] 张恒旭, 李常刚, 刘玉田, 等. 电力系统动态频率分析与应用研究综述[J]. 电工技术学报, 2010, 25(11): 169-176.
Zhang Hengxu, Li Changgang, Liu Yutian, et al. Review of dynamic frequency analysis and application in power systems[J]. Transactions of China Electrotechnical Society, 2010, 25(11): 169-176(in Chinese).
- [12] 王彦博, 吴俊勇, 季佳伸, 等. 基于深度残差收缩网络的电力系统暂态频率安全集成评估[J]. 电网技术, 2023, 47(02): 482-494.
Wang Yanbo, Wu Junyong, Ji Jiashen, et al. Integrated assessment of transient frequency security for power systems based on deep residual shrinkage network[J]. Power System Technology, 2023, 47(02): 482-494(in Chinese).
- [13] 赵冬梅, 郑亚锐, 谢家康, 等. 基于轻量级梯度提升机和生成对抗网络的含风电电力系统频率稳定评估[J]. 电网技术, 2022, 46(08): 3181-3193.
Zhao Dongmei, Zheng Yarui, Xie Jiakang, et al. Frequency stability assessment of wind power included power systems based on lightweight gradient boosting machine and generative adversarial networks[J]. Power System Technology, 2022, 46(08): 3181-3193(in Chinese).
- [14] 文云峰, 赵荣臻, 肖友强, 等. 基于多层极限学习机的电力系统频率安全评估方法[J]. 电力系统自动化, 2019, 43(1): 133-140.
Wen Yunfeng, Zhao Rongzhen, Xiao Youqiang, et al. Frequency safety assessment method for power systems based on multi-layer extreme learning machine[J]. Automation of Electric Power Systems, 2019, 43(1): 133-140(in Chinese).
- [15] Xu L, Li L, Wang M, et al. Online prediction method for power system frequency response analysis based on swarm intelligence fusion model[J]. IEEE Access, 2023, 11: 13519-13532.
- [16] Zhou J, Tong X, Bai S, et al. An attention based E3D-LSTM model for online frequency prediction of post disturbance[C]//2023 6th Asia Conference on Energy and Electrical Engineering (ACEEE). IEEE, 2023: 229-233.
- [17] 邓贤哲, 姚伟, 黄伟, 等. 基于自适应时间窗的数据-模型融合驱动暂态频率预测[J]. 电网技术, 2024, 48(04): 1551-1564.
Deng Xianzhe, Yao Wei, Huang Wei, et al. Transient frequency prediction driven by data-model fusion based on adaptive time window[J]. Power System Technology, 2024, 48(04): 1551-1564.
- [18] Wang G, Wang C, Shahidehpour M. Neural network applications in hybrid data-model driven dynamic frequency trajectory prediction for weak-damping power systems[J]. IEEE Transactions on Power Systems, 2023: 1-13.
- [19] 吴思婕, 王怀远. 基于集成学习的时间自适应电力系统暂态稳定评估方法[J]. 电力系统保护与控制, 2022, 50(24): 113-118.
Wu Sijie, Wang Huaiyuan. Time adaptive transient stability assessment method of power system based on ensemble learning[J]. Power System Protection and Control, 2022, 50(24): 113-118(in Chinese).
- [20] Chen Q, Wang H. Time-adaptive transient stability assessment based on gated recurrent unit[J]. International Journal of Electrical Power and Energy Systems, 2021(133): 1-11.
- [21] 王中冠, 刘嘉琛, 郭力, 等. 基于状态空间映射的模型不完备风电场调频能力在线评估方法[J]. 中国电机工程学报, 2023, 43(03): 927-939.
Wang Zhongguan, Liu Jiachen, Guo Li, et al. Online assessment method of incomplete model wind farm frequency regulation capability based on state space mapping[J]. Proceedings of the Chinese Society for Electrical Engineering, 2023, 43(03): 927-939(in Chinese).
- [22] Guo L, Zhang Y, Li X, et al. Data-Driven power flow calculation method: a lifting dimension linear regression approach[J]. IEEE Transactions on Power Systems, 2022, 37(3): 1798-1808.
- [23] 骆钊, 吴谕侯, 朱家祥, 等. 基于多尺度时间序列块自编码 Transformer 神经网络模型的风电超短期功率预测[J]. 电网技术, 2023, 47(9): 3527-3537.
Luo Zhao, Wu Yuhou, Zhu Jiaxiang, et al. Ultra-short-term wind power prediction based on multi-scale time series block self-coding Transformer neural network model[J]. Power System Technology, 2023, 47(9): 3527-3537(in Chinese).
- [24] 韩宇超, 同向前, 邓亚平. 基于概率密度估计与时序 Transformer 网络的风功率日前区间预测[J/OL]. 中国电机工程学报: 1-11. [2024-03-27]. <http://kns.cnki.net/kcms/detail/11.2107.TM.20230928.1732.004.html>.
Han Yuchao, Tong Xiangqian, Deng Yaping. Day-ahead interval prediction of wind power based on probability density estimation and time-series Transformer network[J/OL]. Proceedings of the Chinese Society for Electrical Engineering : 1-11[2024-03-27]. <http://kns.cnki.net/kcms/detail/11.2107.TM.20230928.1732.004.html> (in Chinese).
- [25] 李练兵, 高国强, 吴伟强, 等. 考虑特征重组与改进 Transformer 的风电功率短期日前预测方法[J]. 电网技术, 2024, 48(04): 1466-1480.
Li Lianbing, Gao Guoqiang, Wu Weiqiang, et al. Short-term day-ahead prediction method for wind power considering feature reorganization and improved Transformer[J/OL]. Power System Technology, 2024, 48(04): 1466-1480(in Chinese).
- [26] Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need[C]//Advances in neural information processing systems. 2017: 5998-6008.
- [27] 房佳姝, 刘崇茹, 苏晨博, 等. 基于自注意力 Transformer 编码器的多阶段电力系统暂态稳定评估方法[J]. 中国电机工程学报, 2023, 43(15): 5745-5759.
Fang Jiaшу, Liu Chongru, Su Chenbo, et al. Multi-stage transient stability assessment method of power system based on self-attention Transformer encoder[J]. Proceedings of the Chinese Society for Electrical Engineering, 2023, 43(15): 5745-5759(in Chinese).
- [28] Khan S, Naseer M, Hayat M, et al. Transformers in vision: a survey[J]. ACM Computing Surveys, 2022, 54(10s): 1-41.
- [29] 高发骏, 王怀远, 党然. 基于 Transformer 的暂态稳定评估模型的可解释性分析与模型更新研究[J]. 电力系统保护与控制, 2023, 51(17): 15-25.
Gao Fajun, Wang Huaiyuan, Dang Ran. Research on interpretability analysis and model update of transient stability assessment model based on Transformer[J]. Power System Protection and Control, 2023, 51(17): 15-25(in Chinese).
- [30] 武妍, 张立明. 神经网络的泛化能力与结构优化算法研究[J]. 计算机应用研究, 2002, (06): 21-25+84.
Wu Yan, Zhang Liming. Research on generalization ability and structure optimization algorithm of neural networks[J]. Computer Applications Research, 2002, (06): 21-25+84(in Chinese).
- [31] 陈海鹏, 李赫, 阚天洋, 等. 考虑风电时序特性的深度小波-时序卷积网络超短期风功率预测[J]. 电网技术, 2023, 47(04): 1653-1665.
Chen Haipeng, Li He, Kan Tianyang, et al. Ultra-short-term wind power prediction based on deep wavelet-temporal convolutional network considering wind power time series characteristics[J]. Power System Technology, 2023, 47(04): 1653-1665(in Chinese).

- [32] 孟安波, 陈顺, 王陈恩, 等. 基于混沌 CSO 优化时序注意力 GRU 模型的超短期风电功率预测[J]. 电网技术, 2021, 45(12): 4692-4700.

Meng Anbo, Chen Shun, Wang Chenen, et al. Ultra-short-term wind power prediction based on chaotic CSO optimized temporal attention GRU model[J]. Power System Technology, 2021, 45(12): 4692-4700(in Chinese).



杨雨昕

杨雨昕 (2001), 女, 硕士研究生, 主要研究方向为新能源电力系统的频率稳定性分析, Email: yangyuxin@hust.edu.cn.

*通信作者: 姚伟(1983), 男, 博士, 教授, 博士生导师, 研究方向为含高比例新能源的交直流电力系统的稳定性分析与控制等, Email: w.yao@hust.edu.cn.



Frequency Stability Index Prediction Based on Koopman Time Series Extension and CNN-Transformer Model

YANG Yuxin¹, *YAO Wei¹, DENG Xianzhe¹, LAN Yutian¹, HUANG Wei², DONG Shitao³, ZHAI Suwei³, WEN Jinyu¹

(1. State Key Laboratory of Advanced Electromagnetic Technology(Huazhong University of Science and Technology), Wuhan 430074, Hubei Province, China; 2. Kunming Power Supply Bureau of Yunnan Power Grid Company Limited, Kunming 650012, Yunnan Province, China; 3. Dispatching Center of Yunnan Power Grid Corporation, Kunming 650011, Yunnan Province, China)

KEY WORDS: frequency stability; CNN-Transformer model; attention visualization; Koopman operator theory; frequency online prediction

With the increasing proportion of new energy in the energy power generation structure, the inertia level of the power system is reduced, which weakens the frequency regulation ability of the system and leads to the increasingly prominent problem of frequency stability. Therefore, it is very important to predict the frequency stability index of the low inertia system after the large disturbance. However, the existing research on frequency index prediction using transient information has the contradiction between prediction accuracy and timeliness : if the input data time is too short, the prediction model has insufficient information and the prediction error increases. If the input data is too long, the prediction accuracy meets the requirements but the prediction timeliness decreases.

Aiming at the above problems, this paper proposes a frequency stability index prediction method based on Koopman timing continuation and CNN-Transformer model. The prediction framework is shown in Fig. 1. Based on the Koopman operator theory, the proposed method extends the time series of the transient data collected in a short time after the disturbance, and then uses the extended long time series as the input feature of the CNN-Transformer model. Compared with the general method, the proposed method not only ensures that the model can obtain sufficient transient information, but also ensures the timeliness of model prediction, and solves the contradiction between prediction accuracy and timeliness.

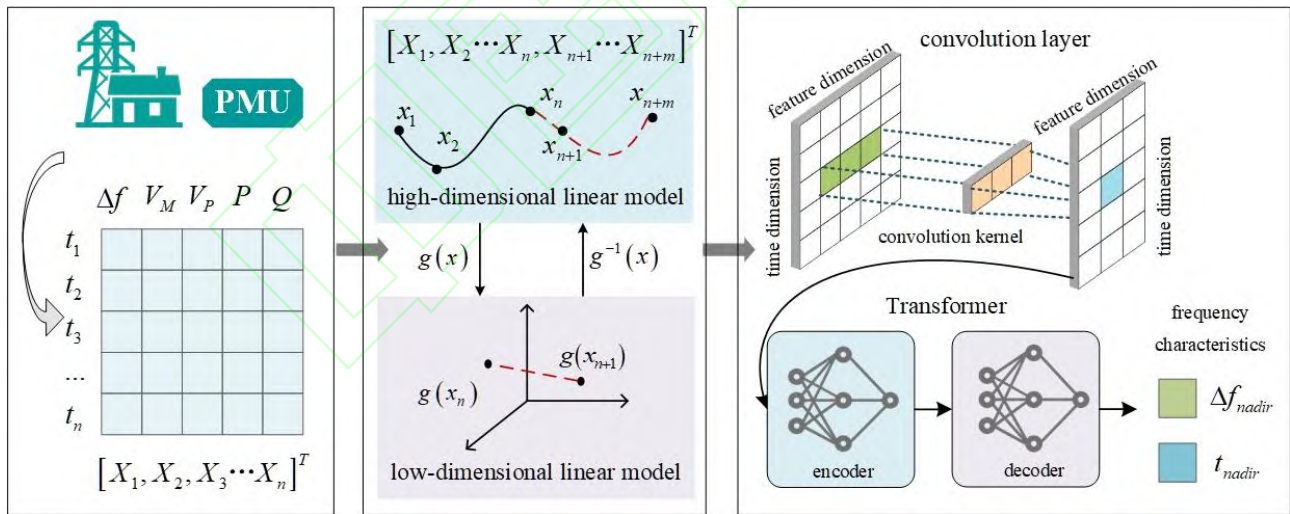


Fig. 1 Framework for frequency stability index prediction based on Koopman time series extension and CNN-Transformer model

The frequency stability index prediction method proposed in this paper combines the time series extension model based on Koopman operator theory with the deep learning prediction model. Compared with the general method, the timeliness of the proposed method is greatly improved, and the prediction time in this example is only 30% of the original. The test results of this method show that the MAPE errors of frequency offset

extremum and its arrival time are 1.02% and 0.11%, respectively. Compared with the commonly used time series prediction models CNN, RNN, LSTM, TCN and GRU, the MAPE errors of frequency offset extremum are reduced by 7.07%, 3.15%, 2.23%, 0.31% and 1.00%, respectively, and the MAPE errors of frequency offset extremum arrival time are reduced by 1.04%, 0.68%, 0.64%, 0.30% and 0.18%, respectively.